Artigo 6 - Model Context Protocol (MCP): Landscape, Security Threats, and Future Research Directions

Aluna: Sofia Vasconcelos Moreira e Silva

O artigo apresenta uma análise abrangente sobre o recém-introduzido *Model Context Protocol* (MCP), um padrão aberto projetado para resolver o problema de isolamento de dados enfrentado pelos sistemas de Inteligência Artificial modernos. Historicamente, cada plataforma de IA exigia integrações personalizadas para acessar fontes de dados externas, como bancos de dados, repositórios de código ou sistemas de arquivos, o que gerava um ecossistema fragmentado e de difícil manutenção. Os autores descrevem o MCP como uma camada de interoperabilidade que permite que modelos de linguagem se conectem a qualquer fonte de dados de maneira padronizada, eliminando a necessidade de reescrever conectores para cada nova aplicação ou ferramenta, promovendo assim uma "teia" de dados conectada para agentes de IA.

A arquitetura do MCP é detalhada como um modelo cliente-servidor, onde os servidores MCP expõem recursos, ferramentas e capacidades de *prompt* de forma agnóstica em relação ao modelo utilizado. O texto explica que essa estrutura permite que os desenvolvedores criem servidores de dados uma única vez, tornando-os acessíveis por qualquer cliente compatível com MCP, como assistentes de codificação ou IDEs. Essa padronização não apenas facilita o desenvolvimento, mas também melhora a qualidade do contexto fornecido ao modelo, já que os dados são transmitidos de forma estruturada. Essa evolução é vista como um passo crítico para a transição de simples "chatbots" para agentes autônomos capazes de interagir com ambientes de software complexos de maneira segura e eficiente.

No entanto, o artigo dedica uma parte significativa à análise das novas ameaças à segurança que surgem com a adoção desse protocolo. Ao permitir que modelos de IA interajam diretamente com sistemas de arquivos e APIs locais, o MCP expande a superfície de ataque para vulnerabilidades como injeção de *prompt* indireta, onde dados maliciosos vindos de um servidor MCP podem manipular o comportamento do modelo para executar comandos não autorizados. Os pesquisadores identificam que a confiança implícita entre o cliente de IA e o servidor MCP pode ser explorada para exfiltração de dados ou execução de código remoto. Essa discussão é vital para a disciplina de Projeto de Software, pois reforça que a facilidade de integração não deve nunca comprometer os princípios de segurança e o controle de acesso granular.

Além das ameaças, o estudo explora o panorama atual de ferramentas que já adotam o protocolo e as direções para pesquisas futuras. Os autores apontam que, embora o MCP simplifique a conectividade, ainda existem desafios em

termos de latência e de como os modelos priorizam informações quando estão conectados a múltiplos servidores simultaneamente. É proposta uma agenda de pesquisa focada no desenvolvimento de mecanismos de segurança mais robustos, como *sandboxing* de servidores MCP e sistemas de verificação de permissões em tempo real. O texto sugere que a evolução do protocolo dependerá da capacidade da comunidade em criar padrões de auditoria e governança que garantam que a automação proporcionada pela IA permaneça sob o controle ético e técnico dos desenvolvedores.

Um ponto de destaque na análise é o impacto do MCP na produtividade e na arquitetura de sistemas orientados a agentes (Agentic Workflows). Ao permitir que um agente de IA alterne entre diferentes fontes de contexto de forma fluida, o protocolo possibilita a criação de sistemas muito mais modulares. Em vez de termos um "monolito de IA" que tenta carregar todos os dados de uma vez, temos microserviços de contexto (servidores MCP) que fornecem apenas o necessário para a tarefa atual. Essa abordagem reduz a carga cognitiva sobre o modelo e economiza *tokens*, tornando as operações mais baratas e precisas. Para o engenheiro de software, isso representa uma mudança de paradigma: o foco sai da "integração de APIs" e passa para a "curadoria de contexto", onde a qualidade da interface de dados define o sucesso da inteligência aplicada.

Concluindo, o trabalho de Hou e seus colaboradores posiciona o MCP não apenas como uma ferramenta técnica, mas como a espinha dorsal de um novo ecossistema de software agentico. O artigo serve como um guia essencial para entender como a IA deixará de ser uma ferramenta isolada para se tornar uma entidade profundamente integrada ao fluxo de trabalho operacional. A conclusão reforça que, para que o MCP atinja seu potencial pleno, a indústria deve equilibrar a inovação e a facilidade de conexão com um rigoroso compromisso com a segurança e a transparência. Para estudantes e profissionais de software, entender o MCP é entender como os sistemas do futuro serão construídos: através de conexões inteligentes, seguras e, acima de tudo, padronizadas.